Gastos de IA durante el desarrollo

DOMINIO · 8 de octubre de 2026 · Clave nueva de Anthropic, modelo Claude Haiku 5.5

Resumen

Hoy se gastaron **~$0.10** en la API de Anthropic, y **todo fue en pruebas de desarrollo**: ningún cliente generó gasto. El **95%** ($0.095) fueron las evaluaciones que compararon niveles de effort y verificaron arreglos. El resto: un chat de prueba, el etiquetado de temas, el escaneo de dominiopr.com y una pregunta al chat de producción.

- **Cuadra con lo que ves en la consola de Anthropic** (~$0.10). Pequeñas diferencias de centavos son por redondeo y por la hora de corte del panel.
- **Cada gasto dejó algo concreto** (sección 3): se eligió el effort, se encontraron y confirmaron tres bugs (fecha para citas, tools que no se ejecutaban, prompt que decía "no hacemos IT") y se validaron el modo clínica, el etiquetado y el escaneo del sitio.
- **Desde la fase 2 cada llamada queda registrada** en el libro de uso, así que estos gastos se ven por cliente y por tipo en el centro de control (/dashboard/control/).

1. Desglose por actividad

Actividad	Hora PR (aprox.)	Llamadas	Tokens entrada / salida	Costo	Para qué
Prueba corta de la API nueva (2 casos)	10:50	4	13,355 / 712	$0.0009	Confirmar que la clave nueva y Haiku 5.5 funcionan.
Eval completo, effort low (58 conversaciones)	11:00	90	338,014 / 14,703	$0.0126	Comparar niveles de effort.
Eval completo, effort medium	11:03	90	338,648 / 18,696	$0.0143	Comparar niveles de effort.
Eval completo, effort high	11:06	90	338,280 / 24,935	$0.0174	Comparar niveles de effort.
Eval completo, effort auto	11:09	90	338,604 / 16,199	$0.0130	Comparar niveles de effort.
Eval de confirmación, low	11:25	92	355,252 / 15,475	$0.0137	Verificar el arreglo de la fecha para citas.
Eval de confirmación, auto	11:28	92	354,567 / 14,912	$0.0133	Verificar el arreglo de la fecha para citas.
Chat de prueba en el servidor local (2 mensajes)	11:38	2	7,280 / 719	$0.0013	Probar el libro de uso en vivo y el arreglo del prompt de IT.
Eval de DOMINIO tras el arreglo de tools (29 casos)	12:30	40	177,281 / 7,329	$0.0070	Confirmar que las tools (lead, cita, humano) se ejecutan.
Eval de modo clínica (7 casos)	12:31	11	47,124 / 2,620	$0.0025	Validar que no pide ni repite datos de salud.
Etiquetado de temas (8 conversaciones)	12:59	8	6,014 / 196	$0.0007	Probar el etiquetado nocturno con la API real.
Escaneo de dominiopr.com (4 páginas)	13:40	1	12,468 / 3,372	$0.0029	Probar el escaneo del sitio con IA.

Actividad	Hora PR (aprox.)	Llamadas	Tokens entrada / salida	Costo	Para qué
Pregunta al chat de producción (1 mensaje)	12:43	1	—	$0.0006	Confirmar en vivo que dominiopr.com ya dice que sí hace IT. (Estimado; queda en el libro de producción).
Total		**611**		**$0.1002**	

"Tokens de entrada" incluye los leídos del caché (cobrados al 10%). Fuente: resumen de cada corrida de agent_eval y el libro de uso (UsageEvent) de la base local.

2. Por categoría

Categoría	Costo	% del total
Evaluaciones (elegir effort y verificar arreglos)	$0.0947	95%
Escaneo de dominiopr.com (4 páginas)	$0.0029	3%
Chat de prueba en el servidor local (2 mensajes)	$0.0013	1%
Etiquetado de temas (8 conversaciones)	$0.0007	1%
Pregunta al chat de producción (1 mensaje)	$0.0006	1%

Tipo de token	Tokens	Precio Haiku 5.5 / millón	Costo aprox.
Entrada sin caché	157,258	$0.10	$0.0157
Salida (respuesta + razonamiento)	119,868	$0.50	$0.0599
Leídos del caché	2,149,695	$0.01	$0.0215
Escritos al caché	19,934	$0.125	$0.0025

El caché sirvió el 93% de la entrada a una décima parte del precio (sin caché, esa entrada habría costado $0.231 en vez de $0.037). La mayor parte del gasto es la salida: las respuestas y el razonamiento del modelo.

3. Lo que dejó cada gasto

- **Effort elegido con datos ($0.057):** low, medium, high y auto dieron el mismo resultado; low es el más rápido y barato. Decisión: low por defecto.
- **Bug de citas encontrado ($0.027 en la verificación):** el agente no sabía la fecha de hoy y no podía agendar "el próximo martes". Arreglado y verificado (58/58).
- **Bug de las tools confirmado ($0.007):** tras un cambio interno, las tools dejaron de ejecutarse; el eval real confirmó el arreglo antes de subir a producción (29/29).
- **Prompt de IT ($0.0019):** el chat local mostró que el agente decía "no hacemos IT" (su copia del conocimiento estaba vieja); tras el deploy, la pregunta a producción confirmó que ahora dice que sí.
- **Modo clínica validado ($0.0025):** no da consejos médicos, no repite datos de salud y manda emergencias al 911 (7/7).
- **Etiquetado y escaneo ($0.0036):** etiquetar 8 conversaciones costó $0.0007; escanear tu sitio, $0.003.

4. Lo que costará en producción

- Un mensaje del chat cuesta ~$0.00017 con Haiku 5.5 (medido). Un cliente típico (300 conversaciones al mes) gasta ~$1 al mes en IA.
- Etiquetar los temas cuesta ~$0.0001 por conversación; escanear un sitio, ~$0.003 por escaneo.
- Los topes diarios por plan y el tope global siguen limitando el gasto máximo.
- El análisis completo de costos y proyecciones está en Analisis-costos-agente-IA.pdf.

Notas: las horas son de Puerto Rico. Las corridas de evaluación anteriores a la fase 2 no están en el libro de uso (no existía); sus cifras salen del resumen que imprimió cada corrida. La pregunta al chat de producción es un estimado: su costo exacto quedó en el libro de uso del servidor.